

如果能够自学，永远比老师教的效果好。老师教的内容一般印象都不深，就像我们走路一样，人家带着你走，七遍八遍也记不住路，自己走一遍就知道路了。

——马志明

第五章

统计与概率

本章导语

数字在我们的日常生活中已经是不可或缺的了，你不相信吗？试着完全不用数字去描述一下昨天你都干了些什么吧！

在日常生活与生产中，那些有意无意被记录下来的数据，到底是“金矿”还是“垃圾”，取决于使用它的人是否有足够多的统计学知识。

统计学是对数据进行收集、整理、展示、分析和解释，以帮助人们更有效地进行决策的科学。现代社会中，大到国家宏观政策的实施，小至个人生活的点点滴滴，都或多或少要用到统计知识。例如，延迟退休决定的做出，一定建立在对人口总体年龄分布等情况的掌握基础上；个人高考志愿的填报，一般会参考所报考院校以往的录取分数线；等等。

概率的有关知识与统计学有千丝万缕的联系，从历史发展来看，概率起源于人们对随机现象统计规律的认识。概率论是研究随机现象统计规律性的学科。我们的生活中充满了随机现象：今天是否会下雨，公交车是否会准点到达，上学的路上会不会遇到自己的好朋友……

本章我们将在初中的基础上，进一步了解统计与概率的知识，并用它们去解决一些更复杂的问题。

例如，俗话说，失败乃成功之母。如果做某一件事，成功的概率只有0.1，那么需要尝试多少次才能保证至少成功一次的概率不小于90%呢？

再例如，某饭店搞“掷骰子得折扣”的活动，顾客同时掷三个骰子，然后按照所得点数情况决定最后的折扣，规则如下图所示。你能分别算出顾客得五五折和七五折的概率吗？



学完本章的内容之后，我们就能轻而易举地解决类似的问题了！

5.1 统计

5.1.1 数据的收集

统计学是一门利用数据帮助人们决策的科学，数据的收集往往是统计活动的基础。现代社会里，获取数据的途径很多。

从互联网上可以获得大量的统计数据。比如从国家统计局的网站（如图 5-1-1 所示）中，通过数据查询等，可以得到各种权威的国家宏观统计数据。



图 5-1-1

再比如，通过正式出版的统计报表和年鉴（如图 5-1-2 所示），也可获得权威的统计数据。

当然，也可以通过向专业人士请教等来获得现成的数据。

我们还可以自己动手直接收集数据。例如，通过社会调查了解人们对环境保护的看法，通过设计试验掌握种子的发芽率，等等。

通过每天的实时记录，也能得到有用的数据。例如，通过记录自己每天在每个学科上学习的时间，能了解自己是否有偏科、是否需要调整各学科的学习时间等。



图 5-1-2

1. 总体与样本



情境与问题

育才中学想在高一年级下学期举办 3 场心理健康讲座，备选的主题有 6 个，高一学生共有 1 356 人。学校将备选的 6 个主题一一列出，做成了调查问卷。为了选出最能满足大家需要的 3 个主题，以下两种方案各自的优点和缺点是什么？

- (1) 请每位高一学生完成调查问卷，然后统计有关结果；
- (2) 随机抽取 50 位高一学生完成调查问卷，然后统计有关结果。

我们在初中已经接触过总体与样本，知道所考察问题涉及的对象全体是**总体**，总体中每个对象都是**个体**，抽取的部分对象组成总体的一个**样本**，一个样本中包含的个体数目是**样本容量**。

一般地，对总体中每个个体都进行考察的方法称为普查（也称为全面调查），只抽取样本进行考察的方法称为抽样调查。前述情境与问题中的方案（1）是普查，方案（2）是抽样调查。

普查能够了解总体中每个个体的情况，从而能准确地掌握总体的特征。因此，在总体包含的个体总数不大，或有特殊需要的情况下，可以采用普查的方法。例如：

- (1) 为了订购集体活动的服装，需要了解班内每位同学的身高、腰围等，应该使用普查的方法；
- (2) 为了全面地了解我国人口状况，从 1949 年至 2017 年，我国已进行了 6 次全国人口普查；
- (3) 为了掌握国民经济第二产业、第三产业的发展规模、结构、效益等信息，我国于 2004 年、2008 年、2013 年进行了三次经济普查，而且自 2013 年以后，计划逢 3 和逢 8 的年份都要进行经济普查。

然而，普查的方法有时会因为各种原因而无法实施，例如成本太高、时间上不容许、考察方法具有破坏性等，此时抽样调查就成了不二选择。例如：

- (1) 想了解潜在顾客对新开发的产品包装意见时，由于潜在顾客难以界定以及经济上的原因，只能采用抽样调查；
 - (2) 想实时了解收看时政新闻的人数等情况，因为经济成本与时间的原
- 因，只能采用抽样调查；
- (3) 国家食品药品监督管理部门想了解各超市中正在出售的牛奶里细菌

含量是否超标，公司质监部门想测试电子产品的防水性能，因为考察方法都具有破坏性，只能采用抽样调查。

事实上，我们在日常生活中也经常运用抽样的思想。例如：

- (1) 早晨起床的时候，如果发现天气变了，你可能会把手伸出窗外感受一下，然后再决定是否要穿厚一点的衣服；
- (2) 在大口喝杯子里的热水之前，你一定会先喝一小口，试一下温度；
- (3) 去买橘子的时候，如果有可能的话，你会先尝一下，然后再决定买还是不买。

当然，对于抽样调查来说，最重要的是要保证所抽取的样本具有代表性，怎样才能做到这一点呢？这正是下面我们要讨论的。



拓展阅读

我国古代统计工作简介

早在夏朝时期，我国就进行了人口调查统计。

为了管理统计工作，周朝设有专门负责调查和记录数据的官员，称为“司书”。据《周礼》的记载，国家设立“司书上士二人，中士四人，府二人，史四人，徒八人”，他们的主要工作是负责“邦之六典……以周知入出百物……以知田野夫家六畜之数”。

《管子》一书中，题为“调查”的那篇记载了 65 个涉及统治一个国家的各方面问题。例如：多少家庭拥有自己的土地和房

屋？每一户储备有多少粮食？有多少鳏夫、寡妇、孤儿和病人？

汉朝的开国皇帝刘邦认为统计很重要，因而他让宰相直接管理统计数字。这作为一个传统，在中国历史上延续了很长一段时间。他们主要感兴趣的问题类似于：当发生紧急状况时能够动员多少身强力壮的男子？需要多少人的劳作才能满足人们的基本生活？在计划做出有关财产或婚姻法律变更时，不满的少数派会有多少？一个地方统治政权以及邻国的课税能力如何？……

2. 简单随机抽样

在初中我们已经接触过简单随机抽样，知道在进行简单随机抽样时，总体中的每一个个体都有相等的机会被抽到。一般地，简单随机抽样（也称为纯随机抽样）就是从总体中不加任何分组、划类、排队等，完全随机地抽取个体。简单随机抽样是其他各种抽样方法的基础。当总体中的个体



图 5-1-3

之间差异程度较小和总体中个体数目较少时，通常采用这种方法。

常见的简单随机抽样方法有抽签法、随机数表法。

抽签法类似于从如图 5-1-3 所示的抽奖箱中抽奖。

例如，若要从 90 个节能灯中用抽签法抽出 5 个来进行检验，可以先给这 90 个节能灯编号，然后将编号写在 90 张纸片（或小球）上，再把纸片放在一个容器中，搅拌均匀后，随机从中抽出 5 个号码，找出这 5 个号码对应的节能灯即可。

抽签法的优点是简单易行，但当总体的容量非常大时，操作起来就比较麻烦，而且如果抽取之前搅拌不均匀，可能导致抽取的样本不具有代表性，使用随机数表可在一定程度上解决这个问题。

顾名思义，随机数表是由随机数（通常为 0, 1, 2, …, 9）形成的数表，表中的每一位置出现的数都是随机的，下列是一个随机数表的一部分。

48628	50089	38155	69882	27761	73903	53014	98720	41571	79413
53666	08912	48395	32616	34905	63640	57931	72328	49195	17699
00620	79613	29901	92364	38659	64526	20236	29793	09063	99398
01114	19048	00895	91770	95934	31491	72529	39980	45750	14155
98246	18957	91965	13529	97168	97299	68402	68378	89201	67871
41410	51595	89983	82330	96809	93877	92818	84275	45938	48490

用随机数表进行简单随机抽样的一般步骤为：

(1) 对总体进行编号。

(2) 在随机数表中任意指定一个开始选取的位置。位置的确定可以闭着眼用手指随机确定，也可用其他方式随机确定。

(3) 按照一定规则选取编号。例如，若编号是两位，规则可以是每次从左往右选取两个数字，也可以是每次只选取每一组的前两个数字，还可以是每次只选取下面一行同一位置对应的两个数字，等等。规则一经确定，就不能更改。在选取过程中，遇到超过编号范围或已经选取了的数字，应该舍弃。

(4) 按照得到的编号找出对应的个体。

例如，仍以从 90 个节能灯中抽出 5 个为例，将 90 个节能灯编号为 01, 02, …, 90：

(1) 若指定从第三行第五组的第一个数字开始，每次从左往右选取两个数字，则可得 5 个编号为

38, 65, 45, 1 , 2 ,

注意，操作过程中共选取了 6 次数，其中第 3 次选取的编号 96 超出了范围，已舍弃；

(2) 若指定从第五行第一组的第一个数字开始, 每次只选取每一组的前两个数字, 则可得 5 个编号为

18, 13, 3 , 4 , 5 ,

注意, 操作过程中共选取了 10 次数.

3. 分层抽样

尝试与发现

某高中高一新生共有 900 人, 其中男生 500 人, 女生 400 人. 学校现在想了解高一新生对文史类课程的看法, 以便开设有关选修课程, 准备从高一新生中抽取 45 人进行访谈:

(1) 如果直接采用简单随机抽样, 会有什么缺点?

(2) 采用怎样的抽样方法较好?

如果相对于要考察的问题来说, 总体是由有明显差别的几部分组成时, 直接采用简单随机抽样得出的样本, 可能并不具有代表性.

例如, 上述尝试与发现中, 一般来说, 男生与女生对文史类课程的看法存在差别, 如果采用简单随机抽样, 得到的样本中, 男生(女生)所占比例与总体中的男生(女生)所占比例可能存在较大差异, 从而导致最后得到的结果不能很好地反映总体的情况.

为了避免出现这种情况, 可以在抽样时要求样本中的男生(女生)所占比例与总体中男生(女生)所占比例一致. 设样本中男生为 x 人, 女生为 y 人, 则应有

$$\frac{x}{45} = \frac{500}{900}, \frac{y}{45} = \frac{400}{900}, \text{ 即 } \frac{x}{500} = \frac{y}{400} = \frac{45}{900},$$

从而有 $x=25$, $y=20$. 这就是说, 应从高一新生的男生中抽取 25 人, 女生中抽取 20 人. 在男生和女生中抽取时, 可以用简单随机抽样的方法.

一般地, 如果相对于要考察的问题来说, 总体可以分成有明显差别的、互不重叠的几部分时, 每一部分可称为层, 在各层中按层在总体中所占比例进行随机抽样的方法称为**分层随机抽样**(简称为**分层抽样**).

通过分层抽样所得到的样本, 一般更具有代表性, 可以更准确地反映总体的特征, 尤其是在层内个体相对同质而层间差异较大时更是如此. 分层抽样在各层中抽样时, 还可根据各层的特点灵活地选用不同的随机抽样方法. 有些情况下, 人们除了对总体的信息感兴趣, 还希望得到各层的内部信息,

这时采用分层抽样更是自然的选择. 因此, 分层抽样方法的应用比较广泛.

例 某科研院所共有科研人员 800 人, 其中具有高级职称的 160 人, 具有中级职称的 320 人, 具有初级职称的 240 人, 无职称的 80 人, 欲了解该科研院所科研人员的创新能力, 决定抽取 100 名科研人员进行调查, 应怎样进行抽样?

解 因为一般来说, 创新能力与职称有关, 所以应该用分层抽样.

设样本中具有高级职称的人数为 x , 则 $\frac{100}{800} = \frac{x}{160}$, 可算得 $x = 20$, 即要抽取具有高级职称的科研人员 20 人.

类似地, 可以算得要抽取具有中级职称的科研人员 **6** 人, 具有初级职称的科研人员 **7** 人, 无职称的科研人员 **8** 人.

在分层抽样过程中, 如果计算得出的层内抽样数不是整数, 可以进行一定的技术处理, 比如将结果取成整数等.

4. 用信息技术进行抽样

很多计算机软件中, 都内置有生成随机数的函数, 我们可以利用这些函数来进行抽样.

例如, 要从 1, 2, ..., 90 中抽出 5 个数, 可以在电子表格软件中多次使用 RANDBETWEEN 函数, 如图 5-1-4 所示.

在 GeoGebra 软件的表格区也可实现同样的功能, 只不过使用的函数是 RandomBetween.

当然, 也可以利用上述命令生成随机数表.

	A	B	C
1	3		
2	8		
3	10		
4	89		
5	=RANDBETWEEN(1, 90)		
6	RANDBETWEEN(bottom, top)		
7			

图 5-1-4

练习A

- ① 如果要了解一批节能灯的寿命, 应该用普查还是抽样调查? 简述理由.
- ② 利用正文中的随机数表, 从第二行第三组第一个数开始, 每次从左往右读三个数字, 从 001, 002, ..., 500 中抽取一个容量为 5 的样本.
- ③ 某完全中学初中部有学生 1 850 人, 高中部有学生 1 250 人. 若要用分层抽样的方法从这所学校抽出 62 名同学来了解大家对学校伙食的看法, 那么所抽出的初中部学生数与高中部学生数的比是多少?



练习B

- ① 某集团有甲、乙、丙三个分公司，其中甲公司有员工 500 名，乙公司有员工 800 名，丙公司有员工 300 名。为了了解集团员工对企业改革的态度，该集团用分层抽样的方式抽取若干名员工进行访谈。已知甲公司共抽取了 10 名员工，分别求乙公司和丙公司抽取的员工数。
- ② 某电视台在互联网上征集电视节目的现场参与观众，报名的共有 12 000 人，分别来自 4 个地区，其中甲地区 2 400 人，乙地区 4 605 人，丙地区 3 795 人，丁地区 1 200 人，主办方计划从中抽取 60 人参加现场节目，请设计一套抽样方案。
- ③ 利用电子表格软件或 GeoGebra 生成一张含有 100 组数的随机数表，并以生成的表为基础，用随机数表法，从编号 001, 002, ..., 600 中抽取容量为 30 的一个样本。

1 26

2 20

3 68

4 89

5 67

6 40

7 30

8 10

5.1.2 数据的数字特征



情境与问题

如下是某学校高一（1）班和高一（2）班某一次期中考试考试的语文成绩，试从不同的角度对两班成绩进行对比。

高一（1）班期中考试语文成绩

69 84 69 80 75 70 75 71 87 70 80 84 73 81 81 73
66 78 68 79 73 75 76 76 70 74 71 86 63 88

高一（2）班期中考试语文成绩

76 86 74 82 77 68 62 82 72 82 76 81 84 79 67 78
70 72 81 89 81 77 72 77 67 67 72 79 81 75 75 84

在日常生活中，当面对一组数据时，相比每一个观测值，有时我们更关心的是能反映这组数据特征的一些值。例如，上述情境中的两个班的成绩，我们可以从最值、平均数、中位数、方差等角度进行比较。