



练习B

- ① 某集团有甲、乙、丙三个分公司，其中甲公司有员工 500 名，乙公司有员工 800 名，丙公司有员工 300 名。为了了解集团员工对企业改革的态度，该集团用分层抽样的方式抽取若干名员工进行访谈。已知甲公司共抽取了 10 名员工，分别求乙公司和丙公司抽取的员工数。
- ② 某电视台在互联网上征集电视节目的现场参与观众，报名的共有 12 000 人，分别来自 4 个地区，其中甲地区 2 400 人，乙地区 4 605 人，丙地区 3 795 人，丁地区 1 200 人，主办方计划从中抽取 60 人参加现场节目，请设计一套抽样方案。
- ③ 利用电子表格软件或 GeoGebra 生成一张含有 100 组数的随机数表，并以生成的表为基础，用随机数表法，从编号 001, 002, ..., 600 中抽取容量为 30 的一个样本。

1 26

2 20

3 68

4 89

5 67

6 40

7 30

8 10

5.1.2 数据的数字特征



情境与问题

如下是某学校高一（1）班和高一（2）班某一次期中考试考试的语文成绩，试从不同的角度对两班成绩进行对比。

高一（1）班期中考试语文成绩

69 84 69 80 75 70 75 71 87 70 80 84 73 81 81 73
66 78 68 79 73 75 76 76 70 74 71 86 63 88

高一（2）班期中考试语文成绩

76 86 74 82 77 68 62 82 72 82 76 81 84 79 67 78
70 72 81 89 81 77 72 77 67 67 72 79 81 75 75 84

在日常生活中，当面对一组数据时，相比每一个观测值，有时我们更关心的是能反映这组数据特征的一些值。例如，上述情境中的两个班的成绩，我们可以从最值、平均数、中位数、方差等角度进行比较。

1. 最值

一组数据的最值指的是其中的最大值与最小值，最值反映的是这组数极端的情况。一般地，最大值用 $\max$ 表示，最小值用 $\min$ 表示。

日常生活中，有时我们只关心数据的最值。比如，高考部分科目实行“一年多考”，最终取的是多次考试成绩中的最大值；举重比赛中，选手有三次“试举”机会，其中成绩的最大值将计入总成绩；末位淘汰的比赛中，积分最小值对应的团体或个人将被淘汰出局；等等。

2. 平均数

日常生活中，我们经常使用平均数来刻画一组数据的平均水平（或中心位置）。例如，为了减少测量的误差，一般取多次测量值的平均数作为最终的测量值；在有多个评委的比赛中，一般也以各评委给出分数的平均数作为最后的成绩；等等。

如果给定的一组数是 $x_1, x_2, \dots, x_n$ ，则这组数的平均数为

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n).$$

这一公式在数学中常简记为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

其中的符号“ $\sum$ ”表示求和，读作“西格玛”， $\sum$ 右边式子中的 i 表示求和的范围，其最小值与最大值分别写在 $\sum$ 的下面与上面。例如，

$$\sum_{i=1}^3 x_i = x_1 + x_2 + x_3, \quad \sum_{i=5}^7 x_i = x_5 + x_6 + x_7.$$

不难看出，求和符号 $\sum$ 具有以下性质：

$$\begin{aligned} (1) \sum_{i=1}^n (x_i + y_i) &= \sum_{i=1}^n x_i + \sum_{i=1}^n y_i; & (2) \sum_{i=1}^n (kx_i) &= k \sum_{i=1}^n x_i; \\ (3) \sum_{i=1}^n t &= nt. \end{aligned}$$

尝试与发现

某武术比赛中，共有 7 个评委，计分的规则是：去掉一个最高分，去掉一个最低分，然后把其他分数的平均数作为选手的最后得分。按照这样的规则，根据以下

数据，计算三位选手的最后得分：

选手	评委 1	评委 2	评委 3	评委 4	评委 5	评委 6	评委 7	最后得分
甲	90	88	93	93	92	92	96	1 _____
乙	92	96	95	92	89	92	95	2 _____
丙	91	91	88	91	98	93	92	3 _____

(1) 从数学的角度，讨论为什么要去掉一个最高分与最低分后再计算平均数，以及平均数具有什么特点；

(2) 有人认为，应该把最高分与最低分之外的分数总分作为选手的最后得分，讨论这样的计分规则与前面的规则是否有本质上的区别。

平均数会受每一个数的影响，尤其是最大值、最小值。很多情况下，为了避免过于极端的值影响结果太大等，会去掉最低分与最高分后再计算平均数。但是，计算总分与计算平均分不会有本质区别，请读者自行说明理由。

当计算上述甲选手的最后得分时，在把 88 与 96 去掉之后，可以先把其余数都减去 92，得到新的数为 -2, 1, 1, 0, 0，因为这一组数的平均数为 0，所以可知甲的最后得分为 92。其余选手的得分可以用类似的方法得到。

一般地，利用平均数的计算公式可知，如果 $x_1, x_2, \dots, x_n$ 的平均数为 $\bar{x}$ ，且 a, b 为常数，则

$$ax_1 + b, ax_2 + b, \dots, ax_n + b$$

的平均数为 $a\bar{x} + b$ ，这是因为

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (ax_i + b) &= \frac{1}{n} \left[\sum_{i=1}^n (ax_i) + \sum_{i=1}^n b \right] = \frac{1}{n} \left(a \sum_{i=1}^n x_i + nb \right) \\ &= a \left(\frac{1}{n} \sum_{i=1}^n x_i \right) + b = a\bar{x} + b. \end{aligned}$$

3. 中位数、百分位数

我们知道，一组数的平均数与这组数中的每一个数都有关，特别地，平均数容易受到最值的影响，因此有时平均数并不能很好地表示这组数的中心位置。

尝试与发现

有甲、乙两个组，每组有 6 名成员，他们暑假读书的本数分别如下：

甲组：1, 2, 3, 3, 4, 5；

乙组：0, 0, 1, 2, 3, 12.

(1) 分别求出两组数的平均数；

(2) 平均数是否很好地表示了每一组数的中心位置？如果没有，可以选择什么数来表示？

上述甲、乙两组数的平均数均为 3，但是用 3 来刻画乙组数的中心位置是不合适的，因为这组数中，有 5 个数都不大于 3.

一般地，有时也可以借助中位数来表示一组数的中心位置：如果一组数有奇数个数，且按照从小到大排列后为 $x_1, x_2, \dots, x_{2n+1}$ ，则称 x_{n+1} 为这组数的中位数；如果一组数有偶数个数，且按照从小到大排列后为 $x_1, x_2, \dots, x_{2n}$ ，则称 $\frac{x_n + x_{n+1}}{2}$ 为这组数的中位数.

尝试与发现

指出甲、乙两组数的中位数，并思考：中位数是否能比较全面地体现数据的分布特点？如果不能，有什么补救的办法？

序号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
甲组	1	2	2	2	2	3	3	3	5	5	6	6	8	8	9	10	10	12	13	13
乙组	0	0	0	0	1	1	2	3	4	5	6	6	7	7	10	14	14	14	14	15

当数据个数较多时，如果仅仅知道中位数，是不足以了解这组数的分布特点的. 例如，上述甲、乙两组数的中位数都是 5.5，但是甲组数中，小于 5.5 的数普遍比乙组的大，而大于 5.5 的数普遍比乙组的小.

更具体地，将甲、乙两组数小于 5.5 的前 10 个数分别看成一组数，则它们的中位数分别是 2.5, **4**，这两个数能够反映甲、乙两组数小于 5.5 的数的分布特点，因为这两个数是通过找小于或等于中位数的所有数的中位数得到的，所以它们分别称为甲、乙两组数的 25% 分位数.

一般地，当数据个数较多时，可以借助多个百分位数来了解数据的分布特点.

一组数的 $p\%$ ($p \in (0, 100)$) 分位数指的是满足下列条件的一个数值：至少有 $p\%$ 的数据不大于该值，且至少有 $(100-p)\%$ 的数据不小于该值.

直观来说，一组数的 $p\%$ 分位数指的是，将这组数按照从小到大的顺序排列后，处于 $p\%$ 位置的数. 例如，中位数就是一个 50% 分位数.

按照定义可知, $p\%$ 分位数可能不唯一, 也正因为如此, 各种统计软件所得出的 $p\%$ 分位数可能会有差异.

为了方便, 我们按如下方式确定 $p\%$ 分位数: 设一组数按照从小到大排列后为 $x_1, x_2, \dots, x_n$, 计算 $i=np\%$ 的值, 如果 i 不是整数, 设 i_0 为大于 i 的最小整数, 取 x_{i_0} 为 $p\%$ 分位数; 如果 i 是整数, 取

$$\frac{x_i + x_{i+1}}{2}$$

为 $p\%$ 分位数. 特别地, 规定: 0 分位数是 x_1 (即最小值), 100%分位数是 x_n (即最大值).

实际应用中, 除了中位数外, 经常使用的是 25%分位数 (简称为第一四分位数) 与 75%分位数 (简称为第三四分位数).

例 1 计算上述尝试与发现中甲、乙两组数的 75%分位数.

解 因为数据个数为 20, 而且

$$20 \times 75\% = 15,$$

所以, 甲组数的 75%分位数为

$$\frac{x_{15} + x_{16}}{2} = \frac{9 + 10}{2} = 9.5;$$

乙组数的 75%分位数为

5

由此可知, 如果尝试与发现中的甲组数用 2.5, 5.5, 9.5 来刻画, 乙组数用 1, 5.5, 12 来刻画, 则大致可以看出它们的数的分布特点.

4. 众数

一组数据中, 某个数据出现的次数称为这个数据的频数, 出现次数最多的数据称为这组数据的众数. 有些情形中, 我们用众数来描述一组数据的中心位置.



情境与问题

某班级准备利用暑假去进行研学旅行, 为了便于识别, 他们准备定做一批容量一致的双肩包, 为此, 活动负责人征求了班内同学的意向, 得到了如下数据:

容量/L	23	25	27	29	31	33
频数	3	2	5	21	2	2

你认为应该定做什么容量的双肩包? 为什么?

为了照顾到绝大多数人的需求，此时应该定做容量为 29 L 的双肩包，这里的 29 就是上述数据的众数。

5. 极差、方差与标准差

一组数的极差指的是这组数的最大值减去最小值所得的差。不难看出，极差反映了一组数的变化范围，描述了这组数的离散程度。

描述一组数的离散程度的量还有方差和标准差。

如果 $x_1, x_2, \dots, x_n$ 的平均数为 $\bar{x}$ ，则方差可用求和符号表示为

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

此时，如果 a, b 为常数，则

$$ax_1 + b, ax_2 + b, \dots, ax_n + b$$

的方差为 $a^2 s^2$ ，这是因为

$$\begin{aligned} & \frac{1}{n} \sum_{i=1}^n [(ax_i + b) - (a\bar{x} + b)]^2 \\ &= \frac{1}{n} \sum_{i=1}^n (ax_i - a\bar{x})^2 = \frac{1}{n} \sum_{i=1}^n [a^2 (x_i - \bar{x})^2] \\ &= a^2 \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = a^2 s^2. \end{aligned}$$

方差的算术平方根称为标准差。由此可知，如果一组数中，各数据值都相等，则标准差为 0，表明数据没有波动，数据没有离散性；若各数据的值与平均数的差的绝对值较大，则标准差也较大，表明数据的波动幅度也较大，数据的离散程度较高。因此标准差描述了数据相对于平均数的离散程度。

例 2 计算下列各组数的平均数与方差：

(1) 18.9, 19.5, 19.5, 19.2, 19, 18.8, 19.5；

(2) 2, 2, 2, 3, 3, 3, 3, 4, 4, 4, 4, 4, 5, 5, 5, 5, 5, 5, 6, 6.

解 (1) 将每一个数乘以 10，再减去 190，可得

$$-1, 5, 5, 2, 0, -2, 5.$$

这组新数的平均数为

$$\frac{1}{7} \times (-1 + 5 + 5 + 2 + 0 - 2 + 5) = 2,$$

方差为

想一想

用 $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})$ 或 $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$ 来衡量一组数的离散程度可以吗？为什么？

$$\frac{1}{7} \times [(-1-2)^2 + (5-2)^2 + (5-2)^2 + (2-2)^2 + (0-2)^2 + (-2-2)^2 + (5-2)^2] = 8.$$

由此可知，所求平均数为 19.2，方差为 $8 \times \frac{1}{100} = 0.08$.

(2) 可将数据整理为

x	2	3	4	5	6
频数	3	4	5	6	2

每一个数都减去 4 可得

$x-4$	-2	-1	0	1	2
频数	3	4	5	6	2

这组数的平均数与方差分别为

$$\frac{1}{20} \times [(-2) \times 3 + (-1) \times 4 + 0 \times 5 + 1 \times 6 + 2 \times 2] = 0,$$

$$\frac{1}{20} \times [(-2)^2 \times 3 + (-1)^2 \times 4 + 0^2 \times 5 + 1^2 \times 6 + 2^2 \times 2] = \frac{3}{2}.$$

因此，所求平均数为 4，方差为 $\frac{3}{2}$.

6. 用信息技术求数据的数字特征

用计算机软件可以方便快捷地求得一组数的各种数字特征.

例如，为了求出例 2 (1) 中数据的数字特征，可以将它们输入电子表格中，然后使用相应的函数即可，如图 5-1-5 所示.

	A	B	C	D	E
1	数据		数字特征	函数名称	计算结果
2	18.9		最大值	MAX	19.5
3	19.5		最小值	MIN	18.8
4	19.5		平均数	AVERAGE	19.2
5	19.2		中位数	MEDIAN	19.2
6	19		第一四分位数	QUARTILE. EXC	18.9
7	18.8		第三四分位数	QUARTILE. EXC	19.5
8	19.5		众数	MODE. SNGL	19.5
9			方差	VAR. P	0.08

图 5-1-5

其中，求第一四分位数输入的是 “=QUARTILE. EXC(A2:A8, 1)”，求第三四分位数输入的是 “=QUARTILE. EXC(A2:A8, 3)”.

用 GeoGebra 软件的表格区也可实现类似的功能，但是函数的名称不一致，如图 5-1-6 所示.

其中,求第一四分位数输入的是“=Percentile[A2:A8, 0.25]”,求第三四分位数输入的是“=Percentile[A2:A8, 0.75]”.

	A	B	C	D	E
1	数据		数字特征	函数名称	计算结果
2	18.9		最大值	Max	19.5
3	19.5		最小值	Min	18.8
4	19.5		平均数	Mean	19.2
5	19.2		中位数	Median	19.2
6	19		第一四分位数	Percentile	18.9
7	18.8		第三四分位数	Percentile	19.5
8	19.5		众数	Mode	{19.5}
9			方差	Variance	0.08

图 5-1-6

练习A

① 已知 $x_1=1, x_2=2, x_3=3, x_4=4, x_5=5$, 求下列各式的值:

$$(1) \sum_{i=1}^3 x_i; \quad (2) \sum_{i=3}^5 x_i; \quad (3) \sum_{i=1}^5 x_i.$$

② 求 1, 2, 3, 4, 5, 6, 7, 8, 9, 10 的 25% 分位数, 75% 分位数, 90% 分位数.

③ 计算下列各组数的平均数与方差:

$$(1) 90, 92, 92, 93, 93; \quad (2) 0, 2, 2, 3, 3; \\ (3) -2, 0, 0, 1, 1; \quad (4) 900, 920, 920, 930, 930.$$

④ 已知 $x_1, x_2, \dots, x_n$ 的平均数为 $\bar{x}$, 求证: $\sum_{i=1}^n (x_i - \bar{x}) = 0$.

练习B

① 已知 12, 10, 15, 9, 8, a 中的最大值为 15, 其中 a 是正整数, 求 a 所有可能的值所组成的集合.

② 求下列各式的值:

$$(1) \sum_{i=1}^3 (2i); \quad (2) \sum_{i=3}^5 (i-2); \quad (3) \sum_{i=1}^5 (2i-1).$$

③ 记 100, 100, 300, 500, 500 的平均数为 a_1 , 标准差为 b_1 ; 200, 200, 300, 400, 400 的平均数为 a_2 , 标准差为 b_2 . 比较 a_1 与 a_2 的大小, b_1 与 b_2 的大小.

$$1 \quad 92 \quad 2 \quad 93.2 \quad 3 \quad 91.6 \quad 4 \quad 1 \quad 5 \quad \frac{x_{15}+x_{16}}{2} = \frac{10+14}{2} = 12$$