

(1) 找出这组数的最值，求出极差；


(2) 以 $[480.5, 487.5)$ 为第一个分组的区间，作出这组数的频率分布直方图.

④ 甲、乙两人某次飞镖游戏中的成绩如下：

甲：8, 6, 7, 7, 8, 10, 9, 8, 7, 8；

乙：9, 10, 6, 7, 9, 9, 10, 8, 9, 10.

其中甲的成绩可用如图 (1) 所示的打点图 (或点状图) 表示，每个成绩上面的点的个数表示这个成绩出现的次数. 在图 (2) 中作出乙的成绩的打点图，并由图写出关于甲、乙成绩比较的两个统计结论.



(第 4 题)

1 51 2 8 3 26 4 $[20, 30)$

5.1.4 用样本估计总体

1. 用样本的数字特征估计总体的数字特征

情境与问题

以下是某学校高一年级 98 位学生的身高 (单位: cm):

161	168	166	168	152	152	163	164	170	167	143	166	153	165
168	167	163	157	160	159	153	169	172	175	165	161	158	172
147	164	171	149	158	155	169	150	173	170	162	157	152	180
178	158	162	164	172	165	165	155	163	178	159	168	161	151
166	168	165	158	162	165	163	166	174	163	163	175	165	160
161	177	163	170	155	156	161	169	167	151	156	158	165	179
161	176	162	168	153	169	155	165	163	166	172	160	173	164

已知这组数的总体平均数为 163.5，总体方差为 56.3.

用简单随机抽样的方法从总体中抽取容量为 10 的样本 3 次，分别计算样本平均数与样本方差，并与总体对应的值进行比较.

一般情况下，如果样本的容量恰当，抽样方法又合理的话，样本的特征能够反映总体的特征. 特别地，样本平均数（也称为样本均值）、方差（也称为样本方差）与总体对应的值相差不会太大.

例如，上述数据中，如果用简单随机抽样抽得的序号分别为 90, 35, 63, 68, 66, 9, 30, 56, 50, 49，则对应的样本为

169, 169, 163, 175, 163, 170, 164, 151, 155, 165,

容易算出，样本均值为 164.4，样本方差为 45.84，它们与总体对应的值差别都不大.

这就说明，在容许一定误差存在的前提下，可以用样本的数字特征去估计总体的数字特征，这样就能节省人力和物力等.

另外，有时候总体的数字特征不可能获得，比如质监部门想知道市场上节能灯的平均使用寿命，不可能把所有节能灯都拿来检测，此时只能用样本的数字特征去估计总体的数字特征.

需要强调的是，估计一般是有误差的. 例如，如果总体平均数记为 μ ，样本均值记为 $\bar{x}$ ，一般来说， $\mu > \bar{x}$ ， $\mu = \bar{x}$ ， $\mu < \bar{x}$ 都有可能. 但是，大数定律可以保证，当样本的容量越来越大时，估计的误差很小的可能性将越来越大.

一般来说，在估计总体的数字特征时，只需直接算出样本对应的数字特征即可.

下面我们来讨论一种稍微复杂一点的情况：假设样本是用分层抽样的方法得到的，而且我们知道了每一层样本的数字特征，该怎样估计总体的数字特征呢？

尝试与发现

在考察某中学的学生身高时，如果采用分层抽样的方法，得到了男生身高的平均数为 170，方差为 16；女生身高的平均数为 165，方差为 25.

(1) 如果没有其他信息，怎样估计总体的平均数与方差？

(2) 如果知道抽取的样本中，男生有 20 人，女生有 15 人，怎样估计总体的平均数与方差？

作为估计来说，我们当然可以选择男生（或女生）样本的平均数与方差

作为总体对应值的估计，但这样的选择没有充分利用已有的数据，显然不够好；另外一种估计的办法是取每一层样本数字特征的算术平均值作为总体的估计，即估计总体平均数为

$$\frac{170+165}{2}=167.5,$$

类似地，总体方差可估计为 **1**_____.

但第二种估计方法也还不太理想，因为对于分层抽样来说，每一层所抽取的个体数目一般来说是不相等的，简单的求数字特征的算术平均值体现不出这一点. 怎样才能体现这一点呢？尤其是，当我们把各层中得到的个体放在一起作为一个样本时，样本均值与样本方差该如何计算呢？此时，当然可以把各层数据集中在一起重新计算，但也可以去考虑整个样本的数字特征与每一层的数字特征之间的关系来实现，后者在大数据时代的并行计算中经常使用.

我们以分两层抽样的情况为例. 假设第一层抽取 m 个数，分别为 $x_1, x_2, \dots, x_m$ ，平均数为 $\bar{x}$ ，方差为 s^2 ；第二层抽取 n 个数，分别为 $y_1, y_2, \dots, y_n$ ，平均数为 $\bar{y}$ ，方差为 t^2 . 则

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, s^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^2,$$

$$\bar{y} = \text{**2**_____}, t^2 = \text{**3**_____}.$$

如果记样本均值为 $\bar{a}$ ，样本方差为 b^2 ，则可以算出

$$\bar{a} = \frac{1}{m+n} \left(\sum_{i=1}^m x_i + \sum_{i=1}^n y_i \right) = \frac{m\bar{x} + n\bar{y}}{m+n},$$

$$b^2 = \frac{m[s^2 + (\bar{x} - \bar{a})^2] + n[t^2 + (\bar{y} - \bar{a})^2]}{m+n}$$

$$= \frac{1}{m+n} \left[(ms^2 + nt^2) + \frac{mn}{m+n} (\bar{x} - \bar{y})^2 \right].$$

依照上述公式可以算出，前述尝试与发现（2）中总体的平均数可以估计为 167.86，总体的方差可以估计为 25.98.

2. 用样本的分布来估计总体的分布

前面我们已经看到，总体的数字特征可以用样本的数字特征来估计，那么，总体的分布是否也可以用样本的分布来近似刻画呢？这是接下来要讨论的问题.

尝试与发现

通过对某中学 1 257 名高一学生期中考试的数学成绩（具体数据参见这一小节的附录）进行整理，可以得到如下数据，并由此可作出频率分布直方图和折线图，如图 5-1-15 所示.

分组	频数	频率
[40, 50)	7	0.01
[50, 60)	65	0.05
[60, 70)	276	0.22
[70, 80)	480	0.38
[80, 90)	330	0.26
[90, 100]	99	0.08




图 5-1-15

从附录的数据中抽取容量为 100 的样本，整理类似的表格，并制作频率分布直方图.

同前面一样，如果样本的容量恰当，抽样方法又合理的话，样本的分布与总体分布会差不多. 特别地，每一组的频率与总体对应的频率相差不会太大.

例如，如果从上述尝试与发现中提到的数据中，抽取两个容量为 100 的样本（分别记为样本 A，样本 B，具体数据参见这一小节的附录），则可以得到如下频数、频率对应表，它们的频率分布直方图分别如图 5-1-16（1）（2）所示.

分组	总体		样本 A		样本 B	
	频数	频率	频数	频率	频数	频率
[40, 50)	7	0.01	0	0	0	0
[50, 60)	65	0.05	5	0.05	8	0.08
[60, 70)	276	0.22	23	0.23	21	0.21
[70, 80)	480	0.38	37	0.37	43	0.43
[80, 90)	330	0.26	27	0.27	19	0.19
[90, 100]	99	0.08	8	0.08	9	0.09

这就说明，同前面一样，如果容许有一定误差，则可以用样本的分布去估计总体的分布. 而且，在总体的分布不可能获得时，只能用样本的分布去估计总体的分布.

同数字特征的估计一样，分布的估计一般也有误差. 如果总体在每一个分组的频率记为 $\pi_1, \pi_2, \dots, \pi_n$ ，样本在每一组对应的频率记为 $p_1, p_2, \dots, p_n$ ，




图 5-1-16

..., p_n , 一般来说,

$$\frac{1}{n} \sum_{i=1}^n (\pi_i - p_i)^2 = \frac{1}{n} [(\pi_1 - p_1)^2 + (\pi_2 - p_2)^2 + \cdots + (\pi_n - p_n)^2]$$

不等于零. 同样, 大数定律可以保证, 当样本的容量越来越大时, 上式很小的可能性将越来越大.

例 1 为了快速了解某学校学生体重 (单位: kg) 的大致情况, 随机抽取了 10 名学生称重, 得到的数据整理成茎叶图如图 5-1-17 所示. 估计这个学校学生体重的平均数和方差.

4	5	9	7	9	6	6
5	1	8	9			
6	0					

图 5-1-17

解 将样本中的每一个数都减去 50, 可得

$$-5, -1, -3, -1, -4, -4, 1, 8, 9, 10,$$

这组数的平均数为

$$\frac{-5-1-3-1-4-4+1+8+9+10}{10}=1,$$

方差为

$$\frac{6^2+2^2+4^2+2^2+5^2+5^2+0^2+7^2+8^2+9^2}{10}=30.4.$$

因此可估计这个学校学生体重的平均数为 51, 方差为 30.4.

例 2 我国是世界上严重缺水的国家之一, 某市为了制定合理的节水方案, 对家庭用水情况进行了调查, 通过抽样, 获得了某年 100 个家庭的月均用水量 (单位: t), 将数据按照 $[0, 1)$, $[1, 2)$, $[2, 3)$, $[3, 4)$, $[4, 5]$ 分成 5 组, 制成了如图 5-1-18 所示的频率分布直方图.




图 5-1-18

- (1) 求图中 a 的值;
- (2) 设该市有 10 万个家庭, 估计全市月均用水量不低于 3 t 的家庭数;
- (3) 假设同组中的每个数据都用该组区间的中点值代替, 估计全市家庭月均用水量的平均数.

解 (1) 因为频率分布直方图所有矩形的面积之和为 1, 所以

$$(0.12 + 0.22 + 0.36 + a + 0.12) \times 1 = 1,$$

解得 $a = 0.18$.

(2) 抽取的样本中, 月均用水量不低于 3 t 的家庭所占比例为

$$(a + 0.12) \times 1 = 0.3 = 30\%,$$

因此估计全市月均用水量不低于 3 t 的家庭所占比例也为 30%, 所求家庭数为 $100\,000 \times 30\% = 30\,000$.

(3) 因为

$$0.12 \times 0.5 + 0.22 \times 1.5 + 0.36 \times 2.5 + 0.18 \times 3.5 + 0.12 \times 4.5 = 2.46,$$

所以估计全市家庭月均用水量的平均数为 2.46.



拓展阅读

用样本估计总体的失败案例

我们已经知道, 用样本估计总体是有可能犯错误的. 下面是美国总统选举中的两个估计失败的案例.

1936 年美国总统选举前, 一家很有名的杂志社, 通过电话簿和各种俱乐部信息等抽取了约 240 万人, 调查他们的选举意向. 根据调查数据, 这家杂志社给出了预测得票率, 但选举结果与预测结果相差很大, 如下表所示.

候选人	预测得票率	实际得票率
罗斯福	43%	62%
兰顿	57%	38%


事实上, 在 1936 年的美国, 一般只有富人才拥有电话、能参加俱乐部, 因此这家

杂志社所得到的样本不能反映总体的情况.

2016 年美国总统选举前, 一个很擅长数据分析的网站, 给出了基于民意调查的两位候选人获胜概率预测, 如下图所示.

然而, 这一次的选举最后以特朗普获胜告终. 实际上, 这次选举绝大多数的预测都是错误的! 原因都与样本的代表性有关.

失败案例的存在是不是意味着用样本估计总体不科学呢? 不是! 这只是说明, 在用样本估计总体时, 要保证抽样方案科学合理. 实际上, 美国总统选举的绝大多数预测都是正确的, 即使是上述两年所说的选举, 也有调查机构根据民意调查正确地预测了结果.



3. “大数据”简介

随着数据收集以及数据存储技术的不断进步，现在人们能够以非常便捷的方式、非常低廉的成本、非常快的速度，收集规模非常宏大的数据集合。“大数据”时代已经悄然来临。


“大数据”的出现，让人们对于“数据”本身有了许多新的认识。除了传统的数值数据外，文本、图像、音频、视频等都可以被“数据化”。网民的搜索行为和浏览记录、法律判决文书、病人的就诊病例和 CT 影像（即计算机层析成像）、聊天语音、视频监控录像等信息都可以被记录下来并且被“数据化”。凡是可以被“数据化”的信息载体都可以看成数据。信息载体包括的数据量达到一定的规模或者达到一定的复杂程度，都可以被认为是“大数据”。

“大数据”的出现，让人们认识到了数据本身的价值：根据网民的搜索行为和浏览记录所反映出来的个人偏好，可以用于精准推送合适的新闻或商品；分析法律判决文书的历史信息，有助于准确识别虚假诉讼、实现案件繁简分离、提高审判效率；将病人的就诊病例、CT 影像数据等与医生的诊断结果结合后，可以用于训练精确的统计模型，实现优质医疗资源共享；准确识别后的语音信息，可以非常快速、便捷地转换为操作指令，提高工作效率；视频监控录像可以为警察破案提供非常重要的线索……

“大数据”的价值远远不止于此。事实上，“大数据”作为信息资源，与土地、劳动力和资本等生产要素一样，正在成为促进经济增长和社会发展的基本要素。“大数据”已被普遍认为是非常重要的国家战略资源。未来，作为重要生产要素和国家战略资源的“大数据”资源，将渗透至我们的日常生活、社会经济活动以及政府管理决策之中，进一步提高我们的生活质量，改进企业的生产效率，提升政府部门快速响应和合理决策的能力，等等。

练习A

- ① 我国古代数学名著《数书九章》有“米谷粒分”题：粮仓开仓收粮，有人送来米 1 534 石，验得米内夹谷，抽样取米一把，数得 254 粒内夹谷 28 粒。估计这批米内所夹的谷有多少石。
- ② 代课教师为了了解某班级学生的数学成绩，随机抽查了 5 位学生的成绩，得到的数据为 92, 78, 56, 75, 62。试估计该班学生数学成绩的平均数与方差。
- ③ 某学校为了了解高中生用手机上网的时间，随机抽查了若干位学生进行调查，收



(第 3 题)

集到的日平均上网时间（单位：h）都在区间 $[0, 3]$ 内，且频率分布直方图如图所示. 分别估计这所学校学生中，日平均上网时间不到 1 h 和超过了 2 h 的学生所占的百分比.

练习B

- ① 为了考察某地 6 月份最高气温的情况，随机抽取了 5 天，所得数据（单位： $^{\circ}\text{C}$ ）可以绘制成如图所示茎叶图. 估计该地 6 月份最高气温的平均值与方差.

2 | 8 9
3 | 0 1 1

（第 1 题）

- ② 为了了解上、下班时段的交通情况，某市抽取了 12 辆机动车行驶的速度，得到了如下数据（单位：km/h）.

上班时段：30 33 18 27 32 40 26 28 21 28 35 20

下班时段：27 19 32 29 36 29 30 22 25 16 17 30

用茎叶图表示这些数据，并分别估计出该市上、下班时段机动车行驶的平均速度.

- ③ 某学校为了调查高一年级学生的体育锻炼情况，从甲、乙、丙 3 个班中，按分层抽样的方法获得了部分学生一周的锻炼时间（单位：h），数据如下.

甲	6	6.5	7	7.5	8			
乙	6	7	8	9	10	11	12	
丙	3	4.5	6	7.5	9	10.5	12	13.5

- (1) 求三个班中学生人数之比；
(2) 估计这个学校高一年级学生中，一周的锻炼时间超过 10 h 的百分比；
(3) 估计这个学校高一年级学生一周的平均锻炼时间.
- ④ 在了解全校学生每年平均阅读了多少本文学经典名著时，甲同学抽取了一个容量为 10 的样本，并算得样本的平均数为 5，方差为 9；乙同学抽取了一个容量为 8 的样本，并算得样本的平均数为 6，方差为 16. 已知甲、乙两同学抽取的样本合在一起组成一个容量为 18 的样本，求合在一起后的样本均值与样本方差.
- ⑤ 记总体在每一个分组的频率为 $\pi_1, \pi_2, \dots, \pi_n$ ，样本在每一组对应的频率记为

$p_1, p_2, \dots, p_n$ ，求证： $\sum_{i=1}^n (\pi_i - p_i) = 0$.

1 $\frac{16+25}{2}=20.5$

2 $\frac{1}{n} \sum_{i=1}^n y_i$

3 $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$

附录

某中学 1 257 名高一学生期中考试数学成绩

69	66	78	78	45	72	89	67	63	71	61	74	77	85	63	76	85
67	59	64	70	79	76	79	62	83	71	65	74	81	98	90	73	89
80	89	78	82	69	78	62	75	70	76	67	66	73	61	80	69	84
58	80	90	78	69	68	81	67	79	68	76	74	71	72	85	80	78
87	97	62	72	69	75	77	67	66	83	80	79	75	87	80	76	74
80	74	53	84	82	72	100	90	76	94	73	73	67	79	82	87	80
68	60	81	64	77	72	69	81	80	58	80	92	58	67	64	100	86
61	64	72	83	60	74	59	74	91	81	70	72	100	90	57	97	74
82	64	68	97	77	89	82	69	67	77	71	69	73	87	83	88	67
78	65	78	72	73	80	74	77	66	80	71	51	75	77	86	60	84
81	79	73	69	75	70	82	68	76	76	92	68	77	89	85	75	73
69	69	77	75	79	64	80	79	55	74	72	82	67	73	70	94	77
64	75	78	73	74	78	84	68	59	79	97	86	81	74	70	76	82
82	75	54	76	85	81	81	79	76	63	76	95	65	83	66	79	83
54	73	62	86	59	96	71	64	80	72	72	89	82	63	58	93	69
89	82	72	71	60	66	60	64	65	74	82	85	73	61	83	78	91
98	74	74	76	85	86	72	51	85	82	80	95	86	58	50	90	91
76	65	91	85	67	90	77	91	80	76	78	76	71	72	82	94	80
79	82	66	65	49	85	82	69	76	85	95	82	74	71	88	65	68
82	86	67	69	71	89	81	85	76	98	94	91	68	78	68	83	87
78	78	71	80	55	73	63	77	73	85	73	70	73	81	79	63	67
67	80	61	57	66	83	82	89	74	72	67	83	92	73	88	81	73
46	76	84	90	62	63	77	61	72	72	49	75	73	90	90	81	63
72	76	65	73	70	78	80	62	90	68	89	82	77	73	84	82	75
74	69	77	84	67	83	93	72	71	75	71	54	74	87	66	70	72
62	91	88	62	79	82	64	75	77	62	77	81	95	78	71	81	84
86	81	71	79	71	78	67	80	83	90	82	62	62	59	79	68	73
85	87	75	67	71	88	58	82	84	63	71	68	95	84	80	60	81
75	86	71	86	81	64	68	70	83	77	84	89	73	87	53	77	82
75	70	73	73	75	66	63	81	76	70	70	59	77	78	71	74	74
83	81	63	79	90	82	75	88	62	81	83	78	67	78	78	64	68
96	75	72	77	60	77	90	77	84	79	62	88	66	78	78	81	84
80	78	61	77	87	55	70	80	71	85	70	75	68	62	68	72	70
70	83	88	73	79	93	76	70	63	79	76	50	74	57	86	75	68
77	74	71	78	83	93	84	70	72	80	70	67	84	95	82	81	77
72	61	80	79	66	68	68	79	76	73	75	82	77	56	66	78	84
60	72	93	65	67	80	93	71	86	73	68	81	66	62	62	53	94
95	83	77	82	79	91	77	77	84	64	85	68	96	56	84	68	85

71	90	48	79	86	72	86	76	67	81	73	75	80	67	71	76	93
78	67	87	78	82	79	70	79	80	82	69	67	88	81	62	77	84
68	57	59	81	77	78	92	89	91	70	85	83	78	72	86	63	83
75	63	68	95	80	81	76	85	68	63	79	69	74	61	77	100	80
84	72	69	82	67	87	69	74	88	75	71	67	75	76	66	79	80
79	72	48	69	82	68	70	65	69	66	76	71	88	74	75	69	79
89	82	80	66	63	76	77	79	68	79	80	73	88	57	81	78	77
69	70	66	69	77	68	54	65	89	66	84	80	76	84	88	71	73
92	67	77	63	90	78	69	81	66	83	67	72	70	93	82	81	64
80	73	92	74	89	87	68	62	89	84	70	76	71	78	72	78	62
67	74	78	72	64	83	80	85	77	88	69	64	70	80	74	57	80
85	82	83	79	69	67	75	81	64	65	64	61	67	88	72	98	76
75	81	84	86	88	80	70	87	67	79	78	70	70	87	74	81	67
65	95	68	63	65	74	82	78	60	67	83	72	85	68	79	85	81
78	92	100	79	62	67	85	75	69	95	69	74	76	69	86	87	78
61	70	83	73	97	74	63	76	82	79	67	79	76	62	83	81	80
79	56	84	92	75	66	99	84	84	73	71	79	73	78	77	93	75
76	73	59	79	70	79	92	64	77	79	60	74	75	56	70	90	59
73	72	68	79	83	83	65	80	86	93	62	75	73	74	73	78	87
75	54	51	73	81	82	95	89	85	77	93	63	54	83	58	68	68
80	77	68	55	68	75	83	79	77	96	73	71	87	60	69	78	84
67	83	89	81	78	77	75	67	62	71	95	83	62	78	90	71	87
81	77	58	55	67	68	88	76	78	67	62	70	80	53	64	71	84
67	86	63	51	75	76	73	71	67	90	78	64	72	59	73	84	93
67	73	84	64	73	75	64	81	77	71	72	83	73	76	93	77	94
69	88	59	73	83	62	64	60	72	62	75	76	76	62	70	84	77
86	76	71	59	96	72	83	87	74	76	69	60	73	78	65	74	85
88	77	74	94	72	74	70	79	92	68	69	47	89	85	87	74	75
70	76	80	69	68	87	63	80	83	56	64	82	80	80	55	59	85
83	73	64	75	67	76	72	81	79	78	90	82	75	79	85	79	68
63	70	82	82	82	57	79	79	71	98	96	78	74	83	70	65	73
70	68	75	59	100	80	55	57	65	80	76	74	55	72	74	70	52
87	85	81	64	68	68	90	70	71	62	72	60	65	78	75	81	73
69	59	75	71	75	70	69	77	80	57	81	93	83	71	87	74	100
70	60	66	70	100	76	89	64	94	77	65	74	74	71	77	57	93
81	78	79	86	82	82	87	78	84	72	54	84	60	56	87	69	

样本 A 的 100 个数据

66	72	71	90	80	76	87	83	87	100	73	87	77	100	91	65	73
77	73	68	76	89	86	80	82	65	69	95	82	73	62	72	78	81
84	78	83	67	75	84	78	61	55	70	88	71	67	66	68	62	77

56 71 81 77 78 63 72 69 89 66 57 80 92 83 65 79 63
83 68 62 69 76 77 56 80 78 75 71 81 77 80 64 73 59
74 85 74 64 72 90 82 74 83 68 83 74 100 71 77

样本 B 的 100 个数据


70 75 67 73 77 67 59 81 74 77 89 73 87 65 74 51 82
75 69 79 70 94 63 60 51 95 76 86 71 78 87 66 90 77
68 93 75 72 81 71 87 58 63 78 80 71 75 76 77 72 77
93 71 94 68 79 67 79 79 59 81 89 83 84 72 88 81 84
67 87 62 78 64 79 62 54 68 77 68 83 77 90 67 76 90
59 72 94 75 70 78 83 64 75 57 62 78 75 73 64

习题5-1A

- ① 已知总体是由编号为 01, 02, ..., 19, 20 的 20 个个体组成. 利用下面的随机数表选取 5 个个体, 选取方法是从随机数表第 1 行的第 5 个数字开始, 由左到右依次选取两个数字. 写出选取的 5 个个体编号.

7816 6572 0802 6314 0702 4369 9728 0198
3204 9234 4935 8200 3623 4869 6938 7481

- ② 已知某地区有小学生 12 000 人, 初中生 11 000 人, 高中生 9 000 人, 现在要了解该地区学生的近视情况, 准备抽取 320 人进行调查, 那么应该抽取小学生、初中生、高中生各多少人?
- ③ 《中国青年报》社会调查中心联合问卷网, 对 2 000 名 18~35 岁青年进行的一项调查显示, 在平时生活中, 18.5% 的受访青年经常会阅读或学习古典诗词, 61.0% 的受访青年偶尔会, 17.9% 的受访青年很少会, 仅 2.6% 的受访青年表示从不接触古典诗词. 选择合适的统计图表表示上述调查结果.
- ④ 截至 2015 年年底, 我国部分省(自治区、直辖市)自然保护区的数量可用下图表示, 写出图中所涉及的这组数的极差和中位数.



(第 4 题)

习题5-1B


- ① 某单位共有 500 名职工，其中不到 35 岁的有 125 人，35~49 岁的有 a 人，50 岁及以上的有 b 人，现用分层抽样的方法，从中抽出 100 名职工了解他们的健康情况：
 - (1) 求不到 35 岁的职工要抽取的人数；
 - (2) 如果已知 35~49 岁的职工抽取了 56 人，求 a 的值，并求 50 岁及以上的职工要抽取的人数。
- ② 已知 $x_1, x_2, \dots, x_n$ 的平均数为 10，标准差为 3，且 $y_i = x_i + 2, i = 1, 2, \dots, n$ 。求 $y_1, y_2, \dots, y_n$ 的平均数与方差。
- ③ 某科技攻关青年团队共有 20 人，他们的年龄分布如下表所示。

年龄	28	29	30	32	36	40	45
人数	1	3	3	5	4	3	1

- (1) 求这 20 人年龄的众数、极差、平均数、方差、25% 分位数、75% 分位数；
- (2) 用茎叶图表示这 20 人的年龄。
- ④ 2015 年，31 个省会城市中，区域声环境质量达到一级的城市为 1 个，达到二级的城市为 22 个，达到三级的城市为 8 个。选择合适的统计图表表示这组数据。
- ⑤ 某学校调查了 20 个班中有网上购物经历的人数，得到了如图所示的茎叶图，以 $[0, 10)$, $[10, 20)$, $[20, 30)$, $[30, 40]$ 为分组，作出这组数的频率分布直方图，并说明频率分布直方图与茎叶图之间的关系。
- ⑥ 下图是 2004—2014 年我国二氧化硫年排放量（单位：万吨）的柱形图，据此评价这些年来我国二氧化硫排放的治理效果。

0	7	3					
1	7	6	4	4	3	0	
2	7	5	5	4	3	2	0
3	8	5	4	3	0		

(第 5 题)



(第 6 题)

习题5-1C

- ① 在发生某公共卫生事件期间，有专业机构认为该事件在一段时间内没有发生大规模群体感染的标志为“连续 10 日，每天新增疑似病例不超过 7 人”。过去 10 日，甲、乙、丙、丁四地新增疑似病例数据信息如下：

甲地：总体平均数为 3，中位数为 4；


乙地：总体平均数为 1，总体方差大于 0；

丙地：中位数为 2，众数为 3；

丁地：总体平均数为 2，总体方差为 3.

则甲、乙、丙、丁四地中，一定没有发生大规模群体感染的有哪些？

- ② 如图所示是某商家根据去年 A, B 两种产品的月销售额（单位：万元）作出的统计图（称为雷达图），根据图中信息，写出关于 A, B 两种产品销售额比较的两个统计结论.



(第 2 题)

- ③ 已知

$$\sum_{i=1}^{10} x_i = 20, \quad \sum_{i=1}^{10} y_i = 10, \quad \sum_{i=1}^{10} x_i y_i = 20,$$

求 $\sum_{i=1}^{10} (x_i - 3)(y_i - 2)$ 的值.

- ④ 在分层抽样时，如果总体分为 k 层，而且第 j 层抽取的样本量为 n_j ，第 j 层的样本均值为 $\bar{x}_j$ ，样本方差为 s_j^2 ， $j=1, 2, \dots, k$. 记 $n = \sum_{j=1}^k n_j$. 求证：所有数据的样本均值和方差分别为

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k (n_j \bar{x}_j), \quad s^2 = \frac{1}{n} \sum_{j=1}^k [n_j s_j^2 + n_j (\bar{x}_j - \bar{x})^2].$$