

第五章

用样本估计总体



学习目标

- 1.会求样本平均数、中位数、众数、**百分位数**.
- 2.会求样本的极差、**标准差**与**方差**.
- 3.了解**频率**与**频数**对总体的估计情况.
- 4.理解用样本的频率分布估计总体的分布的方法.
- 5.通过应用相关知识解决实际统计问题,培养数据分析的核心素养.

核心素养：数学抽象、数学运算、数据分析



新知学习

情景引入

应届毕业生王刚想找一份年薪8万元的工作.有一位招聘员告诉王刚:“我们公司50名员工中,最高年收入达到了100万元,他们平均年收入是10万元,加盟我们公司吧.”

根据以上信息,能否判断王刚可以成为此公司的一名高收入者?如果招聘员继续告诉王刚:“员工年收入的变化范围是从7万元到100万元.” 这个信息是否可以促使王刚做出决定?

一、用样本的数字特征估计总体的数字特征

一般情况下，如果样本的容量恰当，抽样方法又合理的话，样本的特征能够反映总体的特征△特别地，样本平均数（也称为样本均值）、方差（也称为样本方差）与总体对应的值相差不会太大△在容许一定误差存在的前提下，可以用样本的数字特征去估计总体的数字特征，这样就能节省人力和物力等△所以，在估计总体的数字特征时，只需直接算出样本对应的数字特征即可△



二、分层抽样的均值与方差

1. 分层抽样的平均数

(1) 定义: 一般地, 将样本 $a_1, a_2, \dots, a_m$ 和样本 $b_1, b_2, \dots, b_n$ 合并成一个新样本, 则这个新样本的平均数为

$$\frac{a_1 + a_2 + \dots + a_m + b_1 + b_2 + \dots + b_n}{m+n} = \frac{m}{m+n} \cdot \frac{a_1 + a_2 + \dots + a_m}{m} + \frac{n}{m+n} \cdot \frac{b_1 + b_2 + \dots + b_n}{n}.$$

若已知上述两层的新样本中每层的平均数分别为 $\bar{x}_1$ 和 $\bar{x}_2$, 则这个新样本的平均数为 $\frac{m}{m+n} \bar{x}_1 + \frac{n}{m+n} \bar{x}_2$.

记 $w_1 = \frac{m}{m+n}$, $w_2 = \frac{n}{m+n}$, 则这个新样本的平均数为 $w_1 \bar{x}_1 + w_2 \bar{x}_2$, 其中 w_1, w_2 称为权重.

(2) 一般地, 设样本中不同层的平均数和相应权重分别为 $\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n$ 和 $w_1, w_2, \dots, w_n$, 则这个样本的平均数为

$$w_1 \bar{x}_1 + w_2 \bar{x}_2 + \dots + w_n \bar{x}_n. \text{ 记作 } \sum_{i=1}^n w_i \bar{x}_i = w_1 \bar{x}_1 + w_2 \bar{x}_2 + \dots + w_n \bar{x}_n.$$

2. 分层抽样的方差

设样本中不同层的平均数分别为 $\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n$, 方差分别为 $s_1^2, s_2^2, \dots, s_n^2$, 相应的权重分别为 $w_1, w_2, \dots, w_n$, 则这个

样本的方差为 $s^2 = \sum_{i=1}^n w_i [s_i^2 + (\bar{x}_i - \bar{x})^2]$, 其中 $\bar{x}$ 为这个样本的平均数.

即时巩固

1.从一堆苹果中任取5个,称得它们的质量如下(单位:克):

125 124 121 123 127

则该样本的标准差 $s=$ 2(克)(用数字作答).

解析 $\because \bar{x} = \frac{1}{5}(125+124+121+123+127)=124,$

$\therefore s^2 = \frac{1}{5}[(125-124)^2 + (124-124)^2 + (121-124)^2 + (123-124)^2 + (127-124)^2] = 4, \therefore s = 2.$

三.用样本的分布来估计总体的分布

如果样本的容量恰当，抽样方法又合理的话，样本的分布与总体分布会差不多△特别地，每一组的频率与总体对应的频率相差不会太大△

如果容许有一定误差，则可以用样本的分布去估计总体的分布△而且，在总体的分布不可能获得时，只能用样本的分布去估计总体的分布△同数字特征的估计一样，分布的估计一般也有误差△

如果总体在每一个分组的频率记为 $\pi_1, \pi_2, \dots, \pi_n$ ，样本在每一组对应的频率记为 $p_1, p_2, \dots, p_n$ ，一般来说，

$$(\pi_i - p_i)^2 = [(\pi_1 - p_1)^2 + (\pi_2 - p_2)^2 + \dots + (\pi_n - p_n)^2]$$

不等于零△同样，大数定律可以保证，当样本的容量越来越大时，上式很小的可能性将越来越大△

思考 怎样由频率分布直方图估计样本的众数、中位数、平均数?

(1)在频率分布直方图中,众数是最最高的小长方形的中点.(2)在样本中,有50%的个体小于或等于中位数,也有50%的个体大于或等于中位数,因此,在频率分布直方图中,中位数左边和右边的直方图的面积应相等.平均数的估计值等于频率分布直方图中每个小矩形的面积乘以小矩形的底边中点的横坐标之和.

✓ 典例剖析

一、用样本的数字特征估计总体

例1 甲、乙两台机床同时加工直径为100 cm的零件,为检验质量,各从中抽取6件测量,数据为:

甲:99,100,98,100,100,103;

乙:99,100,102,99,100,100.

(1)分别计算两组数据的平均数及方差;

(2)根据计算结果判断哪台机床加工零件的质量更稳定.

解 (1) $\bar{x}_{\text{甲}} = \frac{1}{6}(99+100+98+100+100+103)=100$, $\bar{x}_{\text{乙}} = \frac{1}{6}(99+100+102+99+100+100)=100$.

$$s_{\text{甲}}^2 = \frac{1}{6}[(99-100)^2+(100-100)^2+(98-100)^2+(100-100)^2+(100-100)^2+(103-100)^2] = \frac{7}{3},$$

$$s_{\text{乙}}^2 = \frac{1}{6}[(99-100)^2+(100-100)^2+(102-100)^2+(99-100)^2+(100-100)^2+(100-100)^2] = 1.$$

(2)两台机床所加工零件的直径的平均值相同,又 $s_{\text{甲}}^2 > s_{\text{乙}}^2$,所以乙机床加工零件的质量更稳定.

反思感悟 标准差(方差)的两个作用

(1)标准差(方差)越大,数据的离散程度越大;标准差(方差)越小,数据的离散程度越小.

(2)在实际应用中,常常把平均数与标准差结合起来进行决策.在平均值相等的情况下,比较方差或标准差以确定稳定性.



跟踪训练 (1)据了解,某公司的33名职工月工资(单位:元)如下.


职务	董事长	副董事长	董事	总经理	经理	管理员	职员
人数	1	1	2	1	5	3	20
工资	11 000	10 000	9 000	8 000	6 500	5 500	4 000

该公司职工月工资的平均数为_____ (结果精确到1),中位数为_____,在这两个统计量中,更能反映这个公司员工的工资水平.

(2)某高中从参加学业水平测试的学生中抽出80名学生,其数学成绩(均为整数)的频率分布直方图如图所示.

则这次数学测试的众数是_____.

中位数是_____ (结果精确到0.1).



解析 (1)把工资数据由小到大排列,得到中位数为4 000元.

$$\text{平均数}\bar{x}=\frac{11\,000+10\,000+9\,000\times 2+8\,000+6\,500\times 5+5\,500\times 3+4\,000\times 20}{33}\approx 5\,333(\text{元}).$$

所以中位数更能反映该公司员工的工资水平,平均数受少数人工资额的影响较大,不能反映这个公司员工的工资水平.

(2)由直方图知众数为 $\frac{70+80}{2}=75$.

设中位数为 x ,前三个矩形面积之和为0.4,第四个矩形面积为0.3,因此中位数位于第四个矩形内,由 $0.1=0.03(x-70)$,得 $x\approx 73.3$.

答案 (1)5 333 4 000 中位数 (2)75 73.3

反思感悟

1.因为平均数与每一个样本数据有关,所以任何一个样本数据的改变都会引起平均数的改变,这是众数、中位数不具有的性质,也正因为这个原因,与众数、中位数比较起来,平均数可以反映出更多的关于全体样本数据的信息.但平均数受数据的极端值的影响较大,使平均数在估计总体时可靠性降低.

2.利用频率分布直方图估计数字特征:

(1)众数的估计值是最高的矩形的底边的中点;

(2)中位数的估计值左右两侧直方图的面积相等;

(3)平均数的估计值等于每个小矩形的面积乘以小矩形底边中点的横坐标之和.

二、用样本的分布来估计总体的分布

例2 某省为了了解和掌握2020年高考考生的实际答卷情况,随机地取出了100名考生的数学成绩,数据如下:(单位:分)

135	98	102	110	99	121	110	96	100	103
125	97	117	113	110	92	102	109	104	112
105	124	87	131	97	102	123	104	104	128
109	123	111	103	105	92	114	108	104	102
129	126	97	100	115	111	106	117	104	109
111	89	110	121	80	120	121	104	108	118
129	99	90	99	121	123	107	111	91	100
99	101	116	97	102	108	101	95	107	101
102	108	117	99	118	106	119	97	126	108
123	119	98	121	101	113	102	103	104	108

- (1)列出频率分布表;
- (2)画出频率分布直方图和折线图;
- (3)估计该省考生数学成绩在 $[100,120)$ 分之间的比例.


分析 先求极差.根据极差与数据个数确定组距、组数,然后按频率分布直方图的画法绘制图形.

解 100个数据中,最大值为135,最小值为80,极差为 $135-80=55$.取组距为5,则组数为 $\frac{55}{5}=11$.

(1)频率分布表如下:

分组	频数	频率	$\frac{\text{频率}}{\text{组距}}$
[80,85)	1	0.01	0.002
[85,90)	2	0.02	0.004
[90,95)	4	0.04	0.008
[95,100)	14	0.14	0.028
[100,105)	24	0.24	0.048
[105,110)	15	0.15	0.030
[110,115)	12	0.12	0.024
[115,120)	9	0.09	0.018
[120,125)	11	0.11	0.022
[125,130)	6	0.06	0.012
[130,135]	2	0.02	0.004
合计	100	1.00	0.200

(2)根据频率分布表中的有关信息画出频率分布直方图及折线图,如图所示.



(3)从频率分布表中可知,这100名考生的数学成绩在 $[100,120)$ 分之间的频率为 $0.24+0.15+0.12+0.09=0.60$,据此估计该省考生数学成绩在 $[100,120)$ 分之间的比例为60%.($0.60=60\%$)


反思感悟 组距和组数的确定没有固定的标准,将数据分组时,组数力求合适,使数据的分布规律能较清楚地呈现出来,组数太多或太少都会影响对数据分布情况的了解,若样本容量不超过120个时,按照数据的多少常分为5组~12组,一般样本容量越大,所分组数越多.

跟踪训练 为了了解高一学生的体能情况,某校抽取部分学生进行一分钟跳绳次数测试,将所得数据整理后,画出频率分布直方图如图所示,图中从左到右各小长方形面积之比为2 : 4 : 17 : 15 : 9 : 3,第二小组频数为12.

(1)第二小组的频率是多少?样本容量是多少?

(2)若次数在110或110以上为达标,

试估计该校全体高一学生的达标率是多少?



解 (1) 由于频率分布直方图以面积的形式反映了数据落在各个

小组内的频率大小,因此第二小组的频率为 $\frac{4}{2+4+17+15+9+3}=0.08$.

又因为第二小组频率 $=\frac{\text{第二小组频数}}{\text{样本容量}}$,所以样本容量 $=\frac{\text{第二小组频数}}{\text{第二小组频率}}=\frac{12}{0.08}=150$.

(2)由图可估计该校高一学生的达标率约为 $\frac{17+15+9+3}{2+4+17+15+9+3}\times 100\%=88\%$.

三、分层抽样的有关样本计算


例3 某班50名学生在一次百米测试中,成绩全部介于13秒与19秒之间,将测试结果按如下方式分成六组:[13,14),[14,15),[15,16),[16,17),[17,18),[18,19].如图所示的是按上述分组方法得到的频率分布直方图.设成绩小于17秒的学生人数占全班总人数的百分比为 x ,成绩大于等于15秒且小于17秒的学生人数为 y ,则 x 和 y 分别为()

- A.0.9,35 B.0.9,45 C.0.1,35 D.0.1,45

解析 从频率分布直方图可以看出

$$x = 1 - (0.06 + 0.04) = 0.9, y = 50 \times (0.36 + 0.34) = 35.$$

答案 A



随堂小测


1.从某小学随机抽取100名同学,将他们的身高(单位:cm)数据绘制成频率分布直方图如图所示.由图中数据可知 $a = \underline{0.030}$.若要从身高在 $[120,130)$, $[130,140)$, $[140,150]$ 三组内的学生中,用分层随机抽样的方法选取18人参加一项活动,则从身高在 $[140,150]$ 内的学生中选取的人数为 3.

解析 $\because 0.005 \times 10 + 0.035 \times 10 + a \times 10 + 0.020 \times 10 + 0.010 \times 10 = 1$,

$\therefore a = 0.030$,设身高在 $[120,130)$, $[130,140)$, $[140,150]$ 三组的分别有 x, y, z 人.

$\therefore \frac{x}{100} = 0.030 \times 10, \therefore x = 30$,同理 $y = 20, z = 10$.

$\therefore$ 从 $[140,150]$ 中抽取 $\frac{10}{30+20+10} \times 18 = 3$.



2.若甲、乙、丙、丁四人参加奥运会射击项目选拔赛,四人的平均成绩和标准差如下表:

	甲	乙	丙	丁
平均数 $\bar{x}$	8.5	8.8	8.8	8
标准差 s	3.5	3.5	2.1	8.7

则参加奥运会的最佳人选应为(C)

A.甲 B.乙 C.丙 D.丁

解析 从平均数来看,乙、丙的平均值最大,从标准差来看,丙的标准差最小,因此,应选择丙参加比赛.

3.公交车的数量太多容易造成资源的浪费,太少又难以满足乘客的需求.为此,公交公司在某站台随机调查了80名乘客,他们的候车时间如下所示(单位:min):

17	14	20	12	10	24	18	17	1	22	13	19
28	5	34	7	25	18	28	1	15	31	12	11
10	16	12	9	10	13	19	10	12	12	16	22
17	23	16	15	16	11	9	3	13	2	18	22
19	9	23	28	15	21	28	12	11	14	15	3
11	6	2	18	25	5	12	15	20	16	12	28
20	12	28	15	8	32	18	9				


(1)将数据进行适当的分组,并画出相应的频率分布直方图和频率折线图;

(2)候车时间不低于15分钟比例是多少?你能为公交公司提出什么建议?


解 (1)该数据中最大值为34,最小值为1,两者之差为33,故取组距为5,分为7组.

时间分组	频数	频率	$\frac{\text{频率}}{\text{组距}}$
[0,5)	6	0.075	0.015
[5,10)	9	0.112 5	0.022 5
[10,15)	22	0.275	0.055
[15,20)	22	0.275	0.055
[20,25)	10	0.125	0.025
[25,30)	8	0.100	0.020
[30,35]	3	0.037 5	0.007 5

频率分布直方图如下图所示:



频率折线图如下图所示:



(2)候车时间不低于15分钟的百分比为 $0.275+0.125+0.100+0.0375=0.5375=53.75\%$,
公交公司可以适当增加公交车的数量.



课堂小结

1. 用样本估计总体，就是把随机选取的样本计算数字特征，以此来估计总体的数字特征；把随机选取的样本为依据作出有关图形，直观地表示总体的频率分布。
2. 分层抽样中，已知各层的平均数和方差，求总体的平均数和方差有另外的公式可以方便地求解，不需要使用总体的每一个数据。
3. 用样本数据做出的频率分布直方图，可以近似的表示总体的频率分布直方图，由此估计总体在各段上的频率分布，进而估计总体在各段上的频数，这是统计工作中常用的方法。

谢 谢!